

# Chapter 2

## Hadoop, Hive, Spark with examples

Gaetan Robert Lescouffair  
Sergio Simonian

2020-12-13

## 2.1 Introduction

As soon as we have more data than can be fit in one machine or we want to process more than a single machine can handle in a reasonable time, we tend to redesign our systems to work in a distributed manner. While a distributed system is able to scale horizontally (by adding more machines to the system) it comes with new challenges to tackle. How to optimally distribute the work load across (many different) machines ? How to assure that the system does not interrupt nor produce wrong results in case a machine fails (fault tolerance) or becomes unavailable (partition tolerance) ? Also, it is common that a distributed system serves multiple users and runs several applications at the same time. In that case, how to manage file access rights and resource usage quotas ? And how to make the distributed system appear as a single coherent system to the end-users ? In this chapter we will explore how Hadoop, Hive and Spark handle these challenges for us and provide us with a simple way to achieve distributed storage and parallel processing.

## 2.2 Hadoop

Apache Hadoop is an open-source, cross-platform framework written in Java designed for distributed data storage and parallel data processing. Originally created by Doug Cutting and Mike Cafarella, it is based on two research papers from Google: "The Google File System" (2003) and "MapReduce: Simplified Data Processing on Large Clusters" (2004). It scales up from one machine to large clusters of thousands of machines which may have different hardware capacities (disk, CPU, RAM, and BUS speed). Hadoop plays an important role in both big data storage ranging from structured to unstructured data as well as in distributed computing. The machines in a Hadoop cluster work together to behave as if they were a single system. At the storage level, the sum of all disk capacities on each of the machines equals to the available storage space. At the data processing level, the available computing power is equal to the sum of the power of all the combined CPUs of all the machines in the cluster.

Leading providers of Big Data Database Management Systems are actively implementing the Hadoop platform in their enterprise solutions. For

example, Oracle's "Big Data Appliance" <sup>1</sup> , Microsoft's "Polybase" <sup>2</sup> and IBM's "BigInsights" <sup>3</sup> .

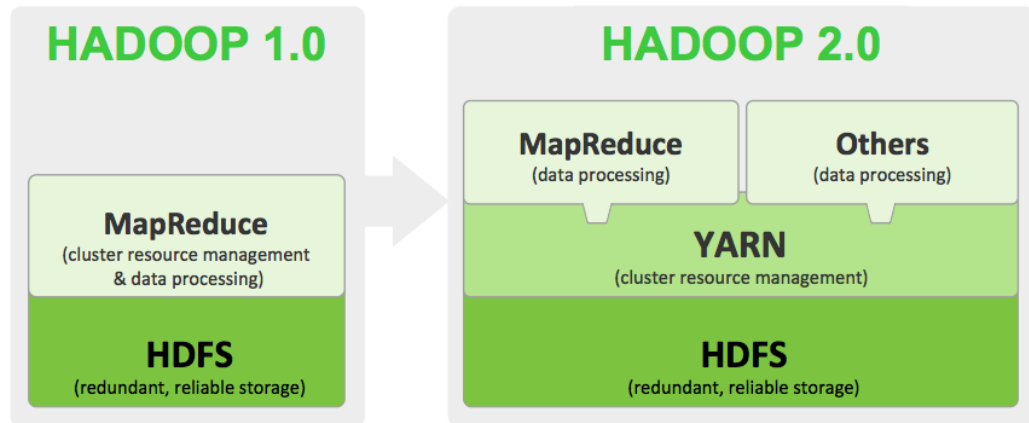


Figure 2.1: Differences between Hadoop 1.0 and Hadoop 2.0 <sup>4</sup>

At the time of this writing, the latest version of Hadoop is 3.3.0. In its version 1 (Figure 2.1) the basic components of Hadoop are: the MapReduce model, which is responsible for the distributed processing and management of cluster resources, and HDFS (Hadoop Distributed File System) for the distributed storage. In its version 2 (Figure 2.1) the MapReduce model plays only the role of distributed processing and Yarn (Yet Another Resource Negotiator) has become the cluster resource manager. This allows Hadoop to have a whole ecosystem around it, including other Frameworks capable of doing distributed data processing, while adding new structures and new ways of making Hadoop work at the application level as well as at the execution level. Finally, in its version 3, improvements are introduced to reduce storage costs while ensuring fault tolerance and to optimize resource management for even greater scalability.

<sup>1</sup><https://docs.oracle.com/en/bigdata/big-data-appliance/5.1/bigug/concepts.html#GUID-8D18CCDF-D5EB-421B-9E5D-13027856EDA0>

<sup>2</sup><https://docs.microsoft.com/en-us/sql/relational-databases/polybase/get-started-with-polybase>

<sup>3</sup>[https://www.ibm.com/support/knowledgecenter/en/SSPT3X\\_4.0.0/com.ibm.swg.im.infosphere.biginights.product.doc/doc/bi\\_editions.html](https://www.ibm.com/support/knowledgecenter/en/SSPT3X_4.0.0/com.ibm.swg.im.infosphere.biginights.product.doc/doc/bi_editions.html)

<sup>4</sup><https://infinitemscript.com/wordpress/wp-content/uploads/2014/08/Differences-between-Hadoop-1-and-2.png>

In the following sections of this chapter, we will look in more detail at how MapReduce, HDFS, Yarn and the ecosystem around Hadoop works, how to install Hadoop and run MapReduce jobs and finally present Apache Hive and Apache Spark and how to use them with examples.

## 2.3 MapReduce

MapReduce is a paradigm designed to simplify data processing on large clusters while ensuring processing reliability and fault tolerance. Its principle is based on the "divide and conquer" technique - it divides the computation into sub-processes and runs them in parallel on the cluster.

A common MapReduce program reads data from HDFS, splits it in parts, assigns for each part a key, groups these parts by their keys and computes a summary for each group.

### **The 4 main steps of a MapReduce process:**

A MapReduce process consists of several steps. Here are the 4 main steps in their corresponding order:

- Split : Split input data into multiple fragments to form subsets of data according to an index such as a space, comma, semicolon, new line, or any other logical rule.
- Map : Map each of the fragments into a new subset where the elements form key-value pairs.
- Shuffle : Group together all the key-value pairs by their respective keys.
- Reduce : Perform a computation on each group of values and output a possible smaller set of values.

### **The general structure of a MapReduce process is in this form :**

Map (key 1, value 1) -> list(key 2, value 2)  
Reduce (key 2, list(value 2)) -> list(key 3, value 3)

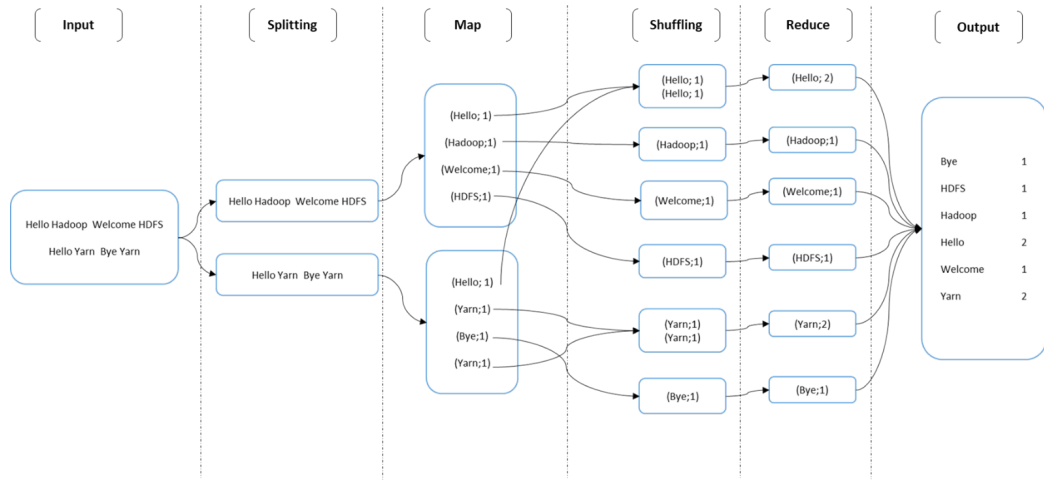


Figure 2.2: MapReduce process steps illustrated with the word counter example

Let's take a closer look of the MapReduce process steps with a word counter example (Figure 2.2). In the following table (Table 2.1), we see for the different steps the shape of the input and output data.

Step	Input	Input type	Output	Output type
Split	Hello Hadoop Wel- come HDFS Hello Yarn Bye Yarn	Text file	(1; "Hello Hadoop Welcome HDFS") (2; "Hello Yarn Bye Yarn")	Fragments of the input file in form of key-value pairs
Map	(1; "Hello Hadoop Welcome HDFS") (2; "Hello Yarn Bye Yarn")	Key- value pairs	(Hello;1), (Hadoop;1), (Welcome;1), (HDFS;1), (Hello; 1), (Yarn;1), (Bye;1), (Yarn;1)	Key-value pairs
Shuffle	(Hello;1), (Hadoop;1), (Welcome;1), (HDFS;1), (Hello; 1), (Yarn;1), (Bye;1), (Yarn;1)	Key- value pairs	[(Hello;1)(Hello;1)], [(Hadoop;1)], [(Welcome;1)], [(HDFS;1)], [(Yarn;1)(Yarn;1)], [(Bye;1)]	Groups of key-value pairs by key
Reduce	[(Hello;1)(Hello;1)], [(Hadoop;1)], [(Welcome;1)], [(HDFS;1)], [(Yarn;1)(Yarn;1)], [(Bye;1)]	Groups of key- value pairs by key	(Hello;2), (Hadoop;1), (Welcome;1), (HDFS;1), (Yarn;2), (Bye;1)	Subset of key-value pairs

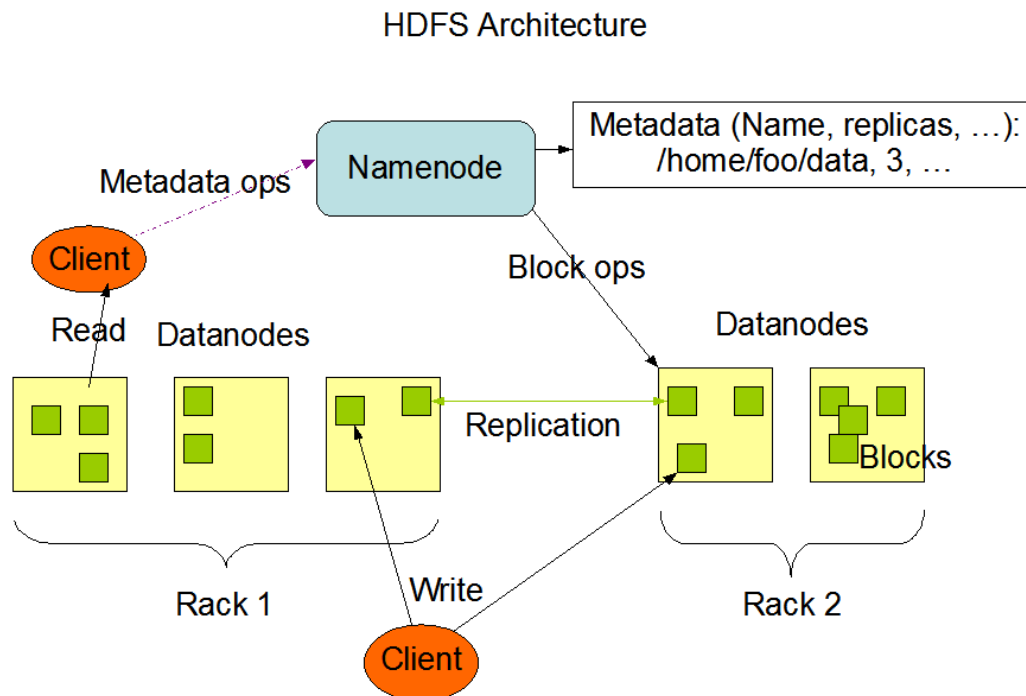
Table 2.1: MapReduce input/output data in the word count example

## 2.4 HDFS

HDFS stands for Hadoop Distributed File System. It is a file system that, from a user perspective, can be compared to others such as Ext, Ext2, Ext3, Ext4, FAT32, NTFS, HFS+ and more. The difference between these file systems is that HDFS is distributed. In HDFS each file is divided into data blocks of 128 MB by default (this size is configurable). Therefore a 1 MB file stored in HDFS has a block size of 128 MB but uses 1 MB of physical disk.

These blocks are then distributed over the entire cluster. Also each block is replicated by default 3 times (this can be configured too) across the cluster in order to assure fault tolerance. In that case, if a node in the cluster becomes unavailable, there will be, for each data block, 2 other nodes that have a replica of the lost block. The reason is to minimize the cost of searching for blocks in the disk. As the speed of disks increases, so does the tendency to increase the block size in HDFS. Hadoop is said to be a distributed file system, the data blocks are distributed across all the machines in the cluster and gives a view of a single disk machine. Because it allows in a single point to access the data distributed over the entire cluster. The data blocks are also replicated so that if one machine fails on the cluster, the system will continue to be available and running without disruption or data loss.

Hadoop supports 3 installation modes: "Local (Standalone)", "Pseudo-Distributed", "Fully-Distributed". By default, Hadoop is configured in "Standalone" mode which runs in a non-distributed mode in a single Java process. In a "Pseudo-Distributed" configuration all the Hadoop daemons are running in separate Java processes on a single node (machine). A Fully-Distributed configuration runs on several machines forming a cluster where each machine runs their respective daemon separately.

Figure 2.3: HDFS Architecture <sup>5</sup>

### HDFS Architecture

- The NameNode daemon, only one in active state for the whole cluster, stores for each file in HDFS its metadata about the name, its directory, the positioning of blocks and replicas on the cluster.
- Le DataNode s'exécutant sur les autres machines du cluster participe au stockage des blocs d'information sur leurs disques. Il est en perpétuel contact avec le NameNode pour tout échange (demande de stockage de blocs, les informations sur les blocs contenue, les statuts, etc.). Les DataNodes communiquent entre eux pour effectuer la réplication des données et signalent le NameNode de son contenu actuel.

Un client qui veut lire ou écrire un fichier dans HDFS contacte le NameNode pour savoir où récupérer ou stocker les blocs de ce dernier.

<sup>5</sup>[https://hadoop.apache.org/docs/r1.2.1/hdfs\\_design.html](https://hadoop.apache.org/docs/r1.2.1/hdfs_design.html)



HDFS est utilisé non seulement pour le stockage des données usuelles, mais aussi le stockage de données temporaires issue des étapes intermédiaires des applications lors de leurs exécutions, et les résultats finals de l'exécution des applications.

## 2.5 Yarn

Yarn is Hadoop's resource manager that distributes tasks to all the machines in the Hadoop cluster and tracks the status of the running tasks.

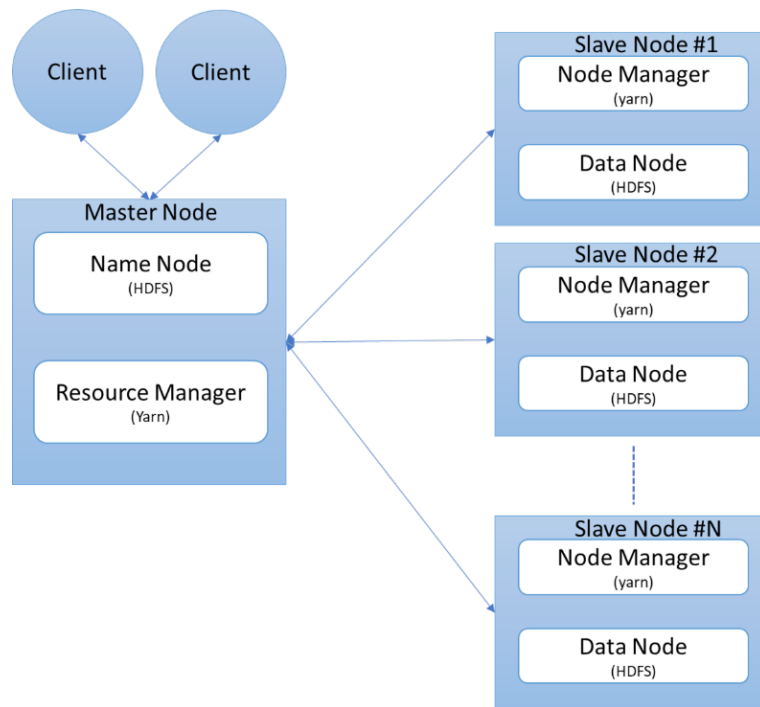


Figure 2.4: Diagram of the positioning of the different daemons on the cluster

Dans l'architecture d'Hadoop Yarn dans un cluster (Figure 2 - 4), le NameNode (nœud Maître) comporte le ResourceManager et les DataNode (nœud Esclave) comportent chacun un NodeManager.

Comme montre, les démons de HDFS sont

Comme on peut le voir dans le schéma suivant (Figure 2 - 5) le rôle de chaque élément au niveau du cluster lorsqu'un ou plusieurs clients envoient une application à être exécutée.

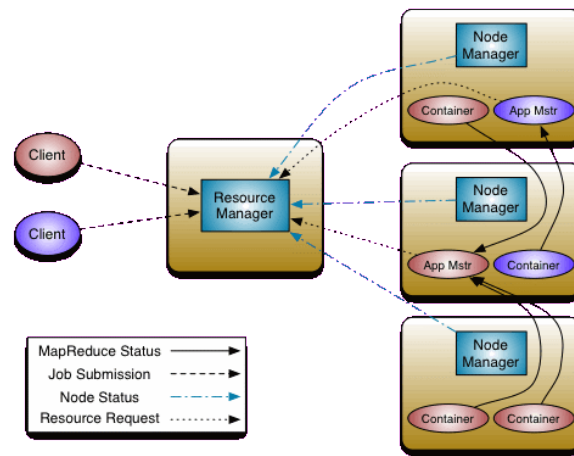


Figure 2.5: Schéma de l'architecture de fonctionnement de Yarn <sup>6</sup>

Un **Client** peut envoyer n'importe quel type d'application reconnue par Yarn.

Le **ResourceManager** fait le suivi des NodeManagers et des ressources disponibles. Il gère l'allocation des ressources disponibles aux applications et aux tâches en évaluant le ou les nœuds les plus optimisés à recevoir l'ensemble des processus à exécuter. En prenant en compte la demande du client, le ResourceManager demande au NodeManager de recevoir une applicationMaster et crée un Container pour son exécution.

Le **NodeManager** fournit pour sa part des ressources pour effectuer les calculs sous forme de conteneurs (Containers) et fait la gestion des processus exécutés par les conteneurs.

L'**ApplicationMaster** fait la coordination de toutes ses tâches en exécution c'est-à-dire les tâches qui ont rapport à sa propre application. Elle fait la demande pour avoir des conteneurs adéquate pour l'exécution de ses tâches.

Les **Containers** (Conteneurs) sont des ressources capables d'exécuter différents types de tâches (Application Masters, Map, Reduce, ...) et peut être dimensionner selon les besoins en termes de RAM et de CPU.

<sup>6</sup>Source : <https://hadoop.apache.org/docs/stable/hadoop-yarn/hadoop-yarn-site/YARN.html>

## 2.6 Ecosystème Hadoop

Hadoop est un Framework qui comprend une panoplie d'outils et technologies autour de lui. Ainsi nous parlons de l'écosystème d'Hadoop. Avant de commencer à travailler avec Hadoop, il est tant essentiel de comprendre son environnement. Chaque outil peut jouer un rôle concret dans différentes parties d'un Project Big Data. La connaissance de son environnement permet de choisir les technologies adéquates pour une meilleure organisation, optimisation de son projet.

L'écosystème d'Hadoop (décrit dans Figure 2- 6) est composé de ces composants principaux (HDFS, MapReduce, Yarn invoqué dans les sections précédentes) et un ensemble d'outils, pour la majorité des projets open-sources d'Apache Software Foundation et des solutions propriétaires. Tous les outils dans son écosystème ont pour but principale l'ingestion, le stockage, l'analyse de données et la maintenance du système.

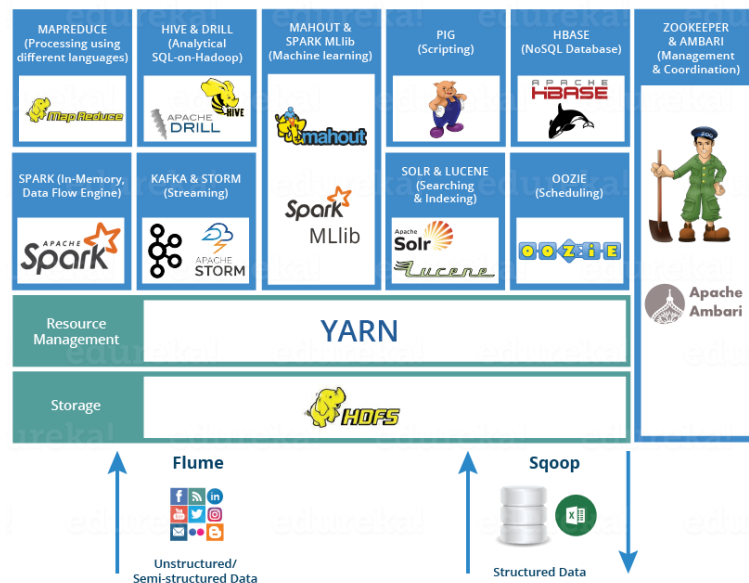


Figure 2.6: Schéma de représentation de l'écosystème d'Hadoop <sup>7</sup>

Le nombre d'outils autour d'Hadoop ne cesse d'augmenter. Dans cette section, on verra un aperçu des outils les plus utilisés actuellement sur le

<sup>7</sup>Source : <https://cdn.edureka.co/blog/wp-content/uploads/2016/10/HADOOP-ECOSYSTEM-Edureka.png>

marché dans le domaine du Big Data.

### 2.6.1 Hive

Apache Hive <sup>8</sup> est un Framework de Data Warehousing permettant à partir d'un interface SQL-like d'effectuer lecture, écriture et la gestion de grand volume de données dans un environnement distribué.

### 2.6.2 Spark

Apache Spark <sup>9</sup> est un Framework pour procéder à de l'analyse de données en utilisant des processus de traitement de données en mémoire dans un environnement distribué.

### 2.6.3 Sqoop

Apache Sqoop <sup>10</sup> est un outil de type ETL (Extract, Transform, Load) conçu pour effectuer des transferts de données en boucle entre Hadoop et les données structurée (base de données relationnelle, fichier CSV, ...) sur de gros volume de manière efficacement.

### 2.6.4 Hbase

Apache HBase <sup>11</sup> est une base de données Hadoop ayant la capacité de gérer l'accès en lecture et écriture de grand volume de données de façon aléatoire et en temps réel. HBase est une base capable de maintenir de très grandes tables pouvant contenir des millions de colonnes.

### 2.6.5 Pig

Apache Pig <sup>12</sup> est une plateforme pour effectuer l'analyse de données sur de grand volume de données. Son langage de très haut niveau, Pig Latin, un langage très textuel ayant des structures de commandes semblable à SQL.

---

<sup>8</sup>Voir <https://hive.apache.org/>

<sup>9</sup>Voir <https://spark.apache.org/>

<sup>10</sup>Voir <http://sqoop.apache.org/>

<sup>11</sup>Voir <https://hbase.apache.org/>

<sup>12</sup>Voir <https://pig.apache.org/>

Lors de sa compilation, il produit de séquences de tâches Map et Reduce déjà capable d'être parallélisé sur Hadoop.

### 2.6.6 Zookeeper

Apache Zookeeper <sup>13</sup> est un gestionnaire de service centralisé dans un environnement distribué. Il permet dans un seul endroit de faire maintenance les informations de configuration et fournit la synchronisation d'information distribué et des services d'énumération et de regroupement.

### 2.6.7 Ambari

Apache Ambri <sup>14</sup> est un outil de gestion qui offre des services simplifiant l'approvisionnement de nouveau service et de sa configuration, la gestion et la surveillance dans des clusters d'Hadoop.

### 2.6.8 Oozie

Apache Oozie <sup>15</sup> est système de planification et de déclenchement d'événement dans Hadoop. Il peut être considéré comme un service d'horloge ou d'alarme interne à Hadoop. Il a la capacité d'exécuter un ensemble d'événements une après l'autre ou de déclencher des événements par rapport à la disponibilité d'information. Les événements lancés peuvent être des tâches map-reduce, Pig, Hive, Sqoop ou programme Java, etc.

### 2.6.9 Apache Solr et Lucene

Apache Solr et Apache Lucene <sup>16</sup> sont une combinaison de deux (2) services qui sont utilisés pour la recherche et l'indexation dans l'environnement Hadoop. Il est adapté pour la réalisation de système d'information nécessitant la recherche sur des textes intégral. Lucene est un composant cœur et Solr est bâti autour de lui ajoutant encore plus de fonctionnalité.

---

<sup>13</sup><https://zookeeper.apache.org/>

<sup>14</sup>Voir <https://ambari.apache.org/>

<sup>15</sup>Voir <http://oozie.apache.org/>

<sup>16</sup>Voir <http://lucene.apache.org/solr/>

### 2.6.10 Kafka

Apache Kalka est un système de messagerie distribué permettant la publication, l'abonnement et l'enregistrement des échanges de flux de données. Il permet la création d'un pipeline de diffusion de données entre des systèmes ou des applications.

### 2.6.11 Storm

Apache Storm est un système de traitement d'informations diffusées en temps réel d'Hadoop pour la réalisation de cas d'usage d'analyse en temps réel, du Machine Learning, la surveillance d'opérations en continue.

### 2.6.12 Flume

Apache Flume est un service distribué de collecte, d'agrégation, de transfert de grand volume de données semi-structurées ou non-structurées de flux en ligne dans HDFS. Ces données sont en provenance de serveur web tel que les fichiers journaux, le trafic réseau, les médias sociales, etc.

### 2.6.13 Drill

Apache Drill est moteur de requête SQL sans schéma pour Hadoop, NoSQL, et Cloud Storage. Il supporte une variété de base de données NoSQL et est capable d'effectuer des requêtes de jointure entre multi-sources de données.

### 2.6.14 Mahout

Apache Mahout <sup>17</sup> fournit un environnement pour le développement d'application de Machine Learning à des performances scalable.

### 2.6.15 Impala

Apache Impala <sup>18</sup> (en projet d'incubation chez Apache) et Presto <sup>19</sup> donnent une bonne appréciation très prometteuse d'eux même dès leur début. Tous

---

<sup>17</sup>Voir <http://mahout.apache.org/>

<sup>18</sup>Voir <https://impala.apache.org/>

<sup>19</sup>Voir <https://prestodb.io/>

les deux sont des moteurs de requête SQL pour les données du Big data. Ils sont capables très rapidement de traiter des données sur des Pétaoctets. Des chercheurs ont publié, chez Cloudera en 2015 « Impala : A Modern, Open-Source SQL Engine for Hadoop »<sup>20</sup> et chez Facebook en 2013 « Presto : Interacting with petabytes of data at Facebook »<sup>21</sup>

## 2.7 Hadoop 3.3.0 cluster installation on Linux Ubuntu 20.04.1 LTS

This section shows the configuration of an Apache Hadoop version 3.3.0 cluster with Yarn. As shown in the following diagram (Figure 2 - 7 ), the installation will be done on three (3) machines with one Master node and two (2) Slave nodes (Slave1 and Slave2).



Figure 2.7: Example Cluster Schema

The machines used for this example installation are inter-connected through a network switch, run Linux Ubuntu 20.04.1 LTS operating system, have

<sup>20</sup>M. Kornacker et al., « Impala: A Modern, Open-Source SQL Engine for Hadoop. », in CIDR, 2015, vol. 1, p. 9.

<sup>21</sup>«Presto: Interacting with petabytes of data at Facebook.» [En Ligne]. Disponible : <https://www.facebook.com/notes/facebookengineering/presto-interacting-with-petabytes-of-data-atfacebook/10151786197628920>.

## 2.7. HADOOP 3.3.0 CLUSTER INSTALLATION ON LINUX UBUNTU 20.04.1 LTS15

about 4G of RAM, 200G free space on their hard drives and Intel i3 processors.

### 2.7.1 Prerequisites

In this section, we will see the preliminary configurations for the operation of Apache Hadoop and some best practices. Since Hadoop is a Java-based platform, in order for it to work, it needs the Java Virtual Machine (JVM) to run. Hadoop 3.3.0 can run on Java 8 or 11. We will install Java 8 because many Hadoop ecosystem components only support Java version up to 8. Another important aspect is that Hadoop uses SSH (Secure Shell) for the connections between the nodes of the cluster. And to avoid security issues, a dedicated user is required to perform all activities related to Hadoop.

#### 2.7.1.1 Install Oracle Java version 8

In the terminal terminal:

Update the package list:

```
sudo apt update
```

Install Java 8 OpenJDK Development Kit:

```
sudo apt install openjdk-8-jdk
```

Check the Java version:

```
java -version
```

The output should look similar to this:

```
openjdk version "1.8.0_275"  
OpenJDK Runtime Environment (build 1.8.0_275-8u275-b01-0ubuntu1~20.04-b01)  
OpenJDK 64-Bit Server VM (build 25.275-b01, mixed mode)
```

#### 2.7.1.2 Hostname configuration

From the start, it is important to determine the host names and IP addresses associated with each machine. Our master node is "hdmaster" and our slave nodes are "hdslave1" and "hdslave2". Make sure that each node has a static IP address so that it does not change over time. This can be done from the



network configuration file (/etc/network/interfaces). Add in the **/etc/hosts** file the **IP addresses, hostnames and aliases** corresponding to each node.

```
sudo nano /etc/hosts
```

```
# IPs, Hostnames and aliases for Hadoop configuration
192.168.2.120 hdmaster hdpdb-master
192.168.2.121 hdslave1 hdpdb-slave1
192.168.2.122 hdslave2 hdpdb-slave2
```

### 2.7.1.3 Create a Hadoop user for HDFS and MapReduce access

We will create a non-root Hadoop user and group both named "hadoop" on each node of the cluster.

```
sudo adduser hadoop
```

### 2.7.1.4 SSH and pdsh installation

```
sudo apt install ssh
sudo apt install pdsh
```

Setup Passwordless SSH access for Hadoop User. Generate the SSH key pair with passphrase in the master node:

```
su - hadoop
ssh-keygen -t rsa -b 4096
cat $HOME/.ssh/id_rsa.pub >> $HOME/.ssh/authorized_keys
chmod 0600 $HOME/.ssh/authorized_keys
```

Then copy the SSH key from Master to the Slaves to initiate SSH access without a password.

```
ssh-copy-id -i $HOME/.ssh/id_rsa.pub hadoop@hdslave1
ssh-copy-id -i $HOME/.ssh/id_rsa.pub hadoop@hdslave2
```

Finally load the password for they SSH key in memory with ssh-agent

```
ssh-agent $SHELL
ssh-add
```

## 2.7. HADOOP 3.3.0 CLUSTER INSTALLATION ON LINUX UBUNTU 20.04.1 LTS17

To check that the Hadoop User has gained passwordless access for the localhost and the slave nodes we will try to initiate a connection with each one.

```
ssh hdoop@localhost
exit
ssh hdoop@hdslave1
exit
ssh hdoop@hdslave2
exit
```

### 2.7.2 Hadoop installation

Download Hadoop (here we will use version 3.3.0). The binary version of Apache Hadoop can be downloaded from the official website (<https://hadoop.apache.org/>). We choose the "/usr/local/" directory for the installation.

```
cd /usr/local/
```

Download the Hadoop archive file

```
sudo wget https://apache.mirrors.benatherton.com/hadoop/common/hadoop-3.3.0
```

Unarchive the newly downloaded file (here hadoop-3.3.0.tar.gz)

```
sudo tar xzf hadoop-3.3.0.tar.gz
```

Give the hdoop user the ownership of the directory

```
sudo chown hdoop:hdoop -R /usr/local/hadoop-3.3.0
```

### Setting up Hadoop environment variables

Switch to the hdoop user

```
sudo su hdoop
```

Add Hadoop environment variables to the end of the hdoop user profile file

```
nano /home/hdoop/.bashrc
```

```

## BEGIN — HADOOP ENVIRONMENT VARIABLES
export JAVA_HOME=/usr/lib/jvm/java-1.8.0-openjdk-amd64
export HADOOP_HOME=/usr/local/hadoop-3.3.0
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"
export PATH=$PATH:$HADOOP_HOME/bin
export PATH=$PATH:$HADOOP_HOME/sbin
## END — HADOOP ENVIRONMENT VARIABLES

```

Make the modification of the profile file active immediately

```
source /home/hadoop/.bashrc
```

Update the Hadoop environment configuration file

```
nano /usr/local/hadoop-3.3.0/etc/hadoop/hadoop-env.sh
```

Find the line defining containing "export JAVA\_HOME=" and update it to:

```
export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64
```

Check if the Hadoop command is now defined

```
hadoop version
```

At this stage, Hadoop is in its default configuration, which also means that it is in "Stand Alone" mode.

## 2.7.3 Configuring Hadoop in fully-distributed mode

### 2.7.3.1 Creation of Hadoop's temporary data directories

In the master node :

```
sudo mkdir -p /usr/local/tmp_hadoop/hdfs/namenode
sudo chown -R hadoop:hadoop /usr/local/tmp_hadoop/
```

In the slave nodes :

## 2.7. HADOOP 3.3.0 CLUSTER INSTALLATION ON LINUX UBUNTU 20.04.1 LTS<sup>19</sup>

```
sudo mkdir -p /usr/local/tmp_hadoop/hdfs/datanode
sudo chown -R hdoop:hdoop /usr/local/tmp_hadoop/
```

### 2.7.3.2 Edit the "workers" file

In the master node:

```
nano /usr/local/hadoop-3.3.0/etc/hadoop/workers
```

Insert all slaves hostnames or IP addresses (one per line)

```
hdslave1
hdslave2
```

### 2.7.3.3 Edit the "core-site.xml" file

The "core-site.xml" file enables us to overwrite Hadoop's default configuration properties from "core-default.xml". Hadoop's official website provides more details about what is configurable in the core-site.xml along with the set default values.<sup>22</sup> For our installation we will set the default file system name property to HDFS and point to our master node.

In the master node and the slave nodes :

```
nano /usr/local/hadoop-3.3.0/etc/hadoop/core-site.xml
```

Insert this property between the opening (<configuration>) and closing (</configuration>) tags.

```
<property>
    <name>fs.default.name</name>
    <value>hdfs://hdmaster:9000</value>
</property>
```

---

<sup>22</sup>See <https://hadoop.apache.org/docs/r3.3.0/hadoop-project-dist/hadoop-common/core-default.xml>

### 2.7.3.4 Edit the "hdfs-site.xml" file

The "hdfs-site.xml" file enables us to overwrite the default configuration for the HDFS client from "hdfs-default.xml". In our example we will configure the block replication factor to 3 and indicate where the NameNode should store the name table (fsimage). For more details about what is configurable in the "hdfs-site.xml" see Hadoop's official website.<sup>23</sup>

In the master node:

```
nano /usr/local/hadoop-3.3.0/etc/hadoop/hdfs-site.xml
```

Insert these properties between the opening (<configuration>) and closing (</configuration>) tags.

```
<property>
    <name>dfs.replication</name>
    <value>3</value>
</property>
<property>
    <name>dfs.namenode.name.dir</name>
    <value>/usr/local/tmp_hadoop/hdfs/namenode</value>
</property>
```

In the slave nodes:

```
nano /usr/local/hadoop-3.3.0/etc/hadoop/hdfs-site.xml
```

Insert these properties between the opening (<configuration>) and closing (</configuration>) tags.

```
<property>
    <name>dfs.replication</name>
    <value>3</value>
</property>
<property>
    <name>dfs.datanode.data.dir</name>
    <value>/usr/local/tmp_hadoop/hdfs/datanode</value>
</property>
```

---

<sup>23</sup>See <https://hadoop.apache.org/docs/r3.3.0/hadoop-project-dist/hadoop-hdfs/hdfs-default.xml>

## 2.7. HADOOP 3.3.0 CLUSTER INSTALLATION ON LINUX UBUNTU 20.04.1 LTS21

### 2.7.3.5 Edit the "yarn-site.xml" file

The "yarn-site.xml" file enables us to overwrite the default configuration for YARN from "yarn-default.xml". In our example we will configure the hostnames and ports used by the Resource Manager, Scheduler and Resource Tracker. We will also configure the shuffle auxiliary service. For more details about what is configurable in the "yarn-site.xml" see Hadoop's official website.<sup>24</sup>

In the master node and the slave nodes :

```
nano /usr/local/hadoop-3.3.0/etc/hadoop/yarn-site.xml
```

Insert these properties between the opening (<configuration>) and closing (</configuration>) tags.

```
<property>
    <name>yarn.resourcemanager.hostname</name>
    <value>hdmaster</value>
</property>
<property>
    <name>yarn.resourcemanager.address</name>
    <value>hdmaster:8032</value>
</property>
<property>
    <name>yarn.resourcemanager.scheduler.address</name>
    <value>hdmaster:8030</value>
</property>
<property>
    <name>yarn.resourcemanager.resource-tracker.address</name>
    <value>hdmaster:8031</value>
</property>
<property>
    <name>yarn.nodemanager.aux-services</name>
    <value>mapreduce_shuffle</value>
</property>
```

---

<sup>24</sup><https://hadoop.apache.org/docs/r3.3.0/hadoop-yarn/hadoop-yarn-common/yarn-default.xml>

### 2.7.3.6 Edit the "mapred-site.xml" file

The "mapred-site.xml" file enables us to overwrite Hadoop's default configuration properties from "mapred-default.xml". Hadoop's official website provides more details about what is configurable in the mapred-site.xml along with the set default values.<sup>25</sup> For our installation we will indicate that we want to use YARN as the runtime framework for executing our MapReduce jobs. We will also indicate where to search for related jar files and packages for our MapReduce applications. In the master node and the slave nodes :

```
nano /usr/local/hadoop-3.3.0/etc/hadoop/mapred-site.xml
```

Insert these properties between the opening (<configuration>) and closing (</configuration>) tags.

```
<property>
    <name>mapreduce.framework.name</name>
    <value>yarn</value>
</property>
<property>
    <name>mapreduce.application.classpath</name>
    <value>${HADOOP_MAPRED_HOME}/share/hadoop/mapreduce/*:${HADOOP_M
</property>
```

### 2.7.3.7 Format the NameNode

In the master node, in order to start HDFS for the first time, it is required to format the NameNode.

```
hdfs namenode -format
```

## 2.7.4 Starting the Hadoop daemons on the cluster

### 2.7.4.1 Starting the HDFS daemons

In the master node:

```
start-dfs.sh
```

<sup>25</sup><http://hadoop.apache.org/docs/r3.3.0/hadoop-mapreduce-client/hadoop-mapreduce-client-core/mapred-default.xml>

## 2.7. HADOOP 3.3.0 CLUSTER INSTALLATION ON LINUX UBUNTU 20.04.1 LTS23

Run this command to check that the HDFS daemons started.

```
jps
```

You should get something similar to this

```
40161 NameNode
40708 Jps
40549 SecondaryNameNode
```

In the slave nodes :

When the NameNode daemon launches, it connects to the slave nodes through SSH. No action is required on the slave nodes.

To check that the slave nodes are properly started we can connect to the with SSH and run this command:

```
jps
```

```
8561 Jps
7753 DataNode
```

### 2.7.4.2 Starting the YARN daemon

In the master node: Run this command to start YARN

```
start-yarn.sh
```

Check that the YARN ResourceManager has started

```
jps
```

The output should be similar to this

```
8128 ResourceManager
8561 Jps
7604 NameNode
7964 SecondaryNameNode
```

In the slave nodes:

Here too, the YARN ResourceManager will connect to the slave nodes and start the NodeManager daemon. No further actions required.

To check the NodeManager has started, connect to the slave nodes and run this command



```
jps
```

The output should be similar to this

```
8561 Jps
8249 NodeManager
7753 DataNode
```

To stop the Hadoop daemons, run the **stop-dfs.sh** and **stop-yarn.sh** scripts as the hadoop user (hdoop in our example).

### Configuration de Yarn et MapReduce pour la gestion et optimisation des ressources

Yarn et MapReduce viennent avec une configuration par défaut. En ajoutant des paramètres dans les fichiers « mapred-site.xml », « yarn-site.xml » et « capacity-scheduler.xml » signifient pour Hadoop qu'il doit considérer ces nouvelles propriétés inscrites au lieu des valeurs par défaut. Dans le but de la gestion et de l'optimisation des ressources partagé et d'utilisation de la mémoire, il faut savoir ou regarder pour trouver l'équilibre idéale pour le bon fonctionnement du système. Une configuration peut bien marché pour une application et non pour une autre par rapport au volume de mémoire demandé au ressources disponible. Anisi, fréquemment des processus d'exécution de plusieurs applications échoue car la taille de mémoire d'ApplicationMaster et d'autres conteneurs dépassent largement la capacité disponible. Ce qui peut impliquer une acceptation de l'application pour être exécuter et que le processus soit resté en fil d'attente ou un arrêt brutal du processus au cours de son exécution.

Les tableaux suivants décrivent la valeur par défaut et la valeur actuelle des propriétés d'ajustement dans leur fichier respectif.

#### mapred-site.xml

## 2.7. HADOOP 3.3.0 CLUSTER INSTALLATION ON LINUX UBUNTU 20.04.1 LTS25

Nom du propriété	Valeur par défaut	Valeur actuelle	description
mapreduce.map.memory.mb	1204	256	
mapreduce.reduce.memory.mb	3072	256	
mapreduce.map.java.opts	-Xm900m	-Xmx205m	
mapreduce.reduce.java.opts	-Xm2560m	-Xmx205m	
yarn.app.mapreduce.am.resource.mb	1536	768	
yarn.app.mapreduce.am.command-opts	-Xm1024m	-Xmx615m	

Table 2.2:

### yarn-site.xml

Nom du propriété	Valeur par défaut	Valeur actuelle	description
yarn.nodemanager.resource.memory-mb		2048	
yarn.scheduler.minimum-allocation-mb	1024	256	
yarn.scheduler.maximum-allocation-mb	8192	1408	
yarn.scheduler.minimum-allocation-vcores	1	1	
yarn.scheduler.maximum-allocation-vcores	32	4	
yarn.scheduler.increment-allocation-mb		128	
yarn.nodemanager.vmem-check-enabled	true	false	
yarn.nodemanager.pmem-check-enabled	true	true	

Table 2.3:

### Création de répertoire et manipulation de fichier dans HDFS

Apache Hadoop fournit un utilitaire de manipulation de fichiers et de répertoires au sein de HDFS. Son utilitaire est « hdfs dfs » ou « hadoop fs », qui sont deux commandes équivalentes.

Création dans HDFS l'arborescence (/user/hdb/input\_ex) des répertoires suivants :

```
hdfs dfs -mkdir -p /user/hdb/input_ex
```

Création de deux fichiers test01 et test02 dans /home/hdb/ en ajoutant les textes respectifs.

```
nano test01
```

```
Hello Hadoop Welcome HDFS
```

```
nano test02
```

```
Hello Yarn Bye Yarn
```

Ajout des fichiers test01 et test02 dans le répertoires /user/hdb/input\_ex dans HDFS précédemment créés

```
hdfs dfs -put /home/hdb/test0* /user/hdb/input_ex
```

Affichage la liste des fichiers dans le répertoire input\_ex

```
hdfs dfs -ls /user/hdb/input_ex
```

Lecture des informations se trouvant dans les fichiers test01 et test02 dans le répertoire input\_ex

```
hdfs dfs -cat /user/hdb/input_ex/test0*
```

## Exemple simple d'exécution d'un programme java MapReduce avec Hadoop

Dans cette section, on verra comment compiler et exécuter un code java MapReduce à partir d'Hadoop en utilisant exemple de base, le compteur de mots (WordCount). Dans l'exemple, l'usage des fichiers test01 et test02 dans le répertoire /user/hdb/input\_ex dans HDFS créés précédemment.

Créer le répertoire suivant pour y déposer le fichier .java et qui par la suite, recevra les autres fichiers générés au cours de la manipulation. Puis se positionner dans le répertoire.

```
mkdir ~/tuto_1
cd ~/tuto_1/
```

Sauvegarder le fichier java dans le répertoire nouvellement crée sous le nom de WordCount.java

### WordCount.java <sup>26</sup>

<sup>26</sup>Source: <https://hadoop.apache.org/docs/r2.8.0/hadoop-mapreduce-client/hadoop-mapreduce-client-core/MapReduceTutorial.html>

## 2.7. HADOOP 3.3.0 CLUSTER INSTALLATION ON LINUX UBUNTU 20.04.1 LTS27

```
import java.io.IOException;
import java.util.StringTokenizer;

import org.apache.hadoop.conf.Configuration;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Job;
import org.apache.hadoop.mapreduce.Mapper;
import org.apache.hadoop.mapreduce.Reducer;
import org.apache.hadoop.mapreduce.lib.input.
    ↪ FileInputFormat;
import org.apache.hadoop.mapreduce.lib.output.
    ↪ FileOutputFormat;

public class WordCount {

    public static class TokenizerMapper
        extends Mapper<Object, Text, Text, IntWritable>{

        private final static IntWritable one = new
            ↪ IntWritable(1);
        private Text word = new Text();

        public void map(Object key, Text value, Context
            ↪ context
                        ) throws IOException,
                        ↪ InterruptedException {
            StringTokenizer itr = new StringTokenizer(value.
                ↪ toString());
            while (itr.hasMoreTokens()) {
                word.set(itr.nextToken());
                context.write(word, one);
            }
        }
    }
}
```

```

public static class IntSumReducer
    extends Reducer<Text,IntWritable,Text,
        ↪ IntWritable> {
    private IntWritable result = new IntWritable();

    public void reduce(Text key, Iterable<IntWritable>
        ↪ values,
                                Context context
                                ) throws IOException,
        ↪ InterruptedException {

        int sum = 0;
        for (IntWritable val : values) {
            sum += val.get();
        }
        result.set(sum);
        context.write(key, result);
    }
}

public static void main(String[] args) throws Exception
    ↪ {
    Configuration conf = new Configuration();
    Job job = Job.getInstance(conf, "word_count");
    job.setJarByClass(WordCount.class);
    job.setMapperClass(TokenizerMapper.class);
    job.setCombinerClass(IntSumReducer.class);
    job.setReducerClass(IntSumReducer.class);
    job.setOutputKeyClass(Text.class);
    job.setOutputValueClass(IntWritable.class);
    FileInputFormat.addInputPath(job, new Path(args[0])
        ↪ );
    FileOutputFormat.setOutputPath(job, new Path(args
        ↪ [1]));
    System.exit(job.waitForCompletion(true) ? 0 : 1);
    }
}

```

Indiquer dans la variable d'environnement CLASSPATH l'ensembles des

## 2.7. HADOOP 3.3.0 CLUSTER INSTALLATION ON LINUX UBUNTU 20.04.1 LTS29

JAR nécessaire à la compilation du programme Java

```
export CLASSPATH="/usr/local/hadoop/share/hadoop/common
➔ /hadoop-common-2.8.0.jar:/usr/local/hadoop/share/
➔ hadoop/mapreduce/hadoop-mapreduce-client-common
➔ -2.8.0.jar:/usr/local/hadoop/share/hadoop/common/
➔ lib/commons-cli-1.2.jar:/usr/local/hadoop/share/
➔ hadoop/mapreduce/hadoop-mapreduce-client-core
➔ -2.8.0.jar"
```

Indiquer à Hadoop avec la variable d'environnement HADOOP\_CLASSPATH où se trouve l'outil de compilation Java à utiliser

```
$ export HADOOP_CLASSPATH=${JAVA_HOME}/lib/tools.jar
```

Compiler le code Java du fichier WordCount.java avec cette ligne :

```
hadoop com.sun.tools.javac.Main WordCount.java
```

Transformer le programme nouvellement compilé en fichier JAR sous le nom de « wc.jar »

```
jar -cf wc.jar WordCount*.class
```

Exécuter le programme MapReduce en lui indiquant en entrée (input) le répertoire (/user/hdb/input\_ex) dans HDFS où se trouvent les fichiers test01 et test02 et en sortie (output) le répertoire (/user/hdb/output\_ex) pour le dépôt des résultats obtenus.

```
hadoop jar wc.jar WordCount /user/hdb/input_ex /user/hdb/output_ex
```

Regarder dans HDFS avec la commande suivante la liste des fichiers créés par le programme WordCount.

```
hadoop fs -ls /user/hdb/output_ex
```

Found 2 items

-rw-r--r--	3	hdb	supergroup	0	2017-08-15 19:29	/user/hdb/output_ex
-rw-r--r--	3	hdb	supergroup	51	2017-08-15 19:29	/user/hdb/output_ex

Le fichier « \_SUCCESS » généré signifie que le programme a bien été exécuté avec succès. Les résultats sont de le fichiers part-r-00000. Selon le

volume d'information à stocker, il peut les séparer en plusieurs parties des numérotations continues avec le préfixe « part-r- ».

Afficher les résultats obtenus :

<code>hadoop fs -cat /user/hdb/output_ex/part-r-*</code>	
Bye	1
HDFS	1
Hadoop	1
Hello	2
Welcome	1
Yarn	2

## 2.8 Hive

Apache Hive est un Framework de Data Warehousing permettant à partir d'un interface SQL-like d'effectuer lecture, écriture et la gestion de grand volume de données dans un environnement distribué. Hive utilise HDFS pour le stockage de ces données. Il a accès (lecture et écriture) à HDFS à travers le nœud maître (NameNode) du cluster d'Hadoop. Hive procure une perception de ces données créées dans HDFS sous forme de base de données et de tables.

Hive expose une liste de services et de fonctionnalité dans son architecture interne (Figure 2 - 8) :

- Il propose 3 clients pour interagir avec Hive. CLI (Hive Command line-interface) est le client Shell par défaut. Beeline aussi une interface de ligne de commande ayant les mêmes fonctionnalités que le CLI avec la possibilité de se connecter avec HiveServer 2 à travers un connecteur JDBC. Le hwi (Hive Web Interface) est un simple client web au même titre que le CLI.
- HiveServer2 est un service fournissant la possibilité de la connexion de multi utilisateurs (application) et d'authentification à Hive à travers Thrift, JDBC, et ODBC.

---

<sup>27</sup>Source: T. White, Hadoop: the definitive guide; [storage and analysis at Internet scale], 4. ed., Updated Beijing: O'Reilly, 2015. p.480




Figure 2.8: Schéma de l'architecture de fonctionnement interne de Hive <sup>27</sup>

- Hive Metastore est un service là pour le stockage des métadonnées concernant la structure des tables et des colonnes associées. Il rend à l'utilisateur une vision de base de données structurée. HCatalog est un API qui permet à d'autres applications d'avoir accès aux métadonnées de Hive Metastore. Hive Metastore peut être configuré de 3 manière :
  - Embedded Metastore (Figure 2- 9) : ce mode utilise Derby comme base de données. La base Metastore et le service de Hive Metastore tournent dans le même processus d'exécution que Hive Server. Il ne peut qu'avoir qu'un utilisateur à la fois.
  - Local Metastore (Figure 2 - 11) : Dans ce mode le service de Hive Metastore tourne dans le même processus d'exécution de HiveServer mais la base de Metastore tourne dans un processus différent et peut être dans un serveur distant.
  - Remote Metastore (Figure 2 - 10) : dans ce mode, le service d'Hive Metastore s'exécute dans un processus séparé de Hive Server et de meme que la base Metastore. HiveServer2, Hcatalog et autre communique lui un API Thrift.

En mode Local et Remote Metastore, le service Hive Metastore utilise un pilote JDBC pour communiquer à la base Metastore.






Figure 2.9: Schéma de l'architecture de fonctionnement interne de Hive <sup>28</sup>




Figure 2.10: Schéma processus Hive en mode Remote Metastore




Figure 2.11: Schéma processus Hive en mode Local Metastore

<sup>28</sup>Source : [http://www.cloudera.com/documentation/cdh/5-1-x/CDH5-Installation-Guide/cdh5ig\\_hive\\_metastore\\_configure.html](http://www.cloudera.com/documentation/cdh/5-1-x/CDH5-Installation-Guide/cdh5ig_hive_metastore_configure.html)

### 2.8.1 Installation de Hive 2.3.0 dans un cluster Hadoop

Cette section montre comment installer Hive sur un cluster d'Hadoop existant (cluster configuré précédemment). Comme on peut voir sur le schéma suivant (figure x), Hive sera mis sur le nœud maitre (Master Node). La configuration sera en « Mode Remote » avec la base de données MySQL pour le stockage des métadonnées en provenance du service de Hive Metastore.




Figure 2.12: Schéma de configuration de Hive sur le cluster d'Hadoop

#### 2.8.1.1 Prérequis

Pour cette configuration de Hive, l'installation du cluster Hadoop doit être déjà mise en place, avec toutes les configurations nécessaires tel que Java 8, création de l'utilisateur, configuration de fichier `/etc/hosts` (voir section 2.5).

#### 2.8.1.2 Pré-configuration pour Hive

Pour la configuration de Hive qui sera effectué, des mises en place sont nécessaires avant de passer à son installation. Dans une première étape, s'effectuera l'installation, configuration de MySQL et mise en place de la base de données pour les données du service de Hive Metastore. Dans un second temps, s'effectuera la création de répertoires d'utilisation de Hive dans HDFS.

### Installation de MySQL pour Hive Metastore

Lancer cette commande pour procéder à l'installation de MySQL

```
sudo apt-get install mysql-server
```

Lancer les services de mysql

```
sudo service mysql start
```

Installation du connecteur de MySQL. Ce connecteur permettra à Hive Metastore service de se connecter à la base de données qui sera créée dans MySQL. Hive fait usage de pilote JDBC pour communiquer avec MySQL.

```
sudo apt-get install libmysql-java
```

Création d'un lien symbolique dans le répertoire lib de Hive afin qu'il puisse avoir une référence dans connecteur JDBC chez lui.

```
sudo ln -s /usr/share/java/mysql-connector-java.jar /  
↪ usr/local/hive/lib/mysql-connector-java.jar
```

Renforcement de sécurité de MySQL avec l'utilitaire de sécurité

```
sudo /usr/bin/mysql_secure_installation
```

Faites comme suit :

```
...  
Enter current password for root (enter for none):  
OK, successfully used password, moving on...  
...  
Set root password? [Y/n] y  
New password:  
Re-enter new password:  
Remove anonymous users? [Y/n] Y  
...  
Disallow root login remotely? [Y/n] N  
...  
Remove test database and access to it [Y/n] Y  
...  
Reload privilege tables now? [Y/n] Y  
All done!
```

Changer le paramètre bind-address dans le fichier mysqld.cnf par son adresse IP du serveur pour avoir un accès distant à la base de données.

```
sudo nano /etc/mysql/mysql.conf.d/mysqld.cnf
```

```
#find this line and change localhost to your server-ip  
bind-address = 192.168.2.120
```

Connecter en tant que root à MySQL

```
mysql -u root -p  
enter password:
```

Dans l'invite de commande de MySQL, utiliser la commande suivante pour créer la base de données de Hive Metastore à partir du fichier hive-schema-2.3.0.mysql.sql qui permet de créer la base de données de MySQL pour la version 2.3.0 de Hive. Ce script se trouve déjà à votre disposition dans les répertoires de Hive.

```
CREATE DATABASE metastore;  
USE metastore;  
SOURCE /usr/local/hive-2.3.0/scripts/metastore/upgrade  
↪ /mysql/hive-schema-2.3.0.mysql.sql
```

Toujours dans l'invite de commande de MySQL, passer les commandes suivantes pour la creation de l'utilisateur hive pour donner access à la base metastore au service de Hive.

```
CREATE USER 'hive'@'hdmaster' IDENTIFIED BY 'hive!hive'  
↪ ;  
REVOKE ALL PRIVILEGES, GRANT OPTION FROM 'hive'@'  
↪ hdmaster';  
GRANT ALL PRIVILEGES ON metastore.* TO 'hive'@'hdmaster'  
↪ ;  
  
CREATE USER 'hive'@'' IDENTIFIED BY 'hive!hive';REVOKE ALL  
PRIVILEGES, GRANT OPTION FROM 'hive'@'GRANT ALL  
PRIVILEGES ON metastore.* TO 'hive'@'CREATE USER  
'hive'@'192.168.2.120' IDENTIFIED BY 'hive!hive';REVOKE ALL  
PRIVILEGES, GRANT OPTION FROM  
'hive'@'192.168.2.120';GRANT ALL PRIVILEGES ON metastore.* TO  
'hive'@'192.168.2.120';FLUSH PRIVILEGES;quit;
```

Arrêter et redémarrer le démon de MySQL pour prendre en compte les modifications des fichiers de configuration.

```
sudo /etc/init.d/mysql stop
sudo /etc/init.d/mysql start
```

Vérifier bien si l'utilisateur hive a la possibilité de se connecter à MySQL à l'hôte hdmaster

```
mysql -h hdmaster -u hive -p
```

**Creation des répertoires d'utilisation de Hive dans HDFS** Créer dans HDFS 2 répertoires et assigner les droits lecture et écriture : /tmp répertoire de données temporaire de Hive lors de l'exécution de tâches et /user/hive/warehouse répertoire pour la création des bases et tables.

```
hdfs dfs -mkdir /tmp
hdfs dfs -mkdir /user/hive/warehouse

hdfs dfs -chmod g+w /tmp
hdfs dfs -chmod g+w /user/hive/warehouse
```

## Installation de Hive

On fera usage de la version 2.2.0 de Hive. La version binaire d'Apache Hive peut être récupérée sur le site officiel (<https://hive.apache.org/>) Allez dans le répertoire partager pour que Hive puisse être exécuté par un autre utilisateur. Nous faisons le choix du répertoire /usr/local/ pour l'installation comme pour l'installation d'Hadoop.

```
cd /usr/local/
```

Allez sur le site officiel de hive dans téléchargement pour trouver le lien.

```
sudo wget http://apache.mirrors.ovh.net/ftp.apache.org/dist/hive/hive-
```

Désarchiver le fichier nouvellement téléchargé (ici apache-hive-2.3.0-bin.tar.gz) et renommer le répertoire obtenu en hive-2.3.0.

```
sudo tar -zxvf apache-hive-2.3.0-bin.tar.gz
sudo mv apache-hive-2.3.0-bin hive-2.3.0
```

Donner l'utilisateur hdb la propriété sur répertoire

```
sudo chown hdb:hadoop -R /usr/local/hive-2.3.0
```

**Mise en place des variables d'environnement d'Hive** Se connecter en tant que hdb

```
sudo su hdb
```

Ajouter les variables d'environnement d'Hive dans le fichier profile de l'utilisateur hdb

```
nano /home/hdb/.bashrc
```

```
#Add to the end of this file
# — HIVE ENVIRONMENT VARIABLE START — #
export HIVE_HOME=/usr/local/hive-2.3.0
export PATH=$PATH:$HIVE_HOME/bin
export CLASSPATH=$CLASSPATH:usr/local/hadoop-2.8.0/lib/*:.
export CLASSPATH=$CLASSPATH:/usr/local/hive-2.3.0/lib/*:.

# — HIVE ENVIRONMENT VARIABLE END — #
```

Rendre la modification du fichier profile active immédiatement

```
source /home/hdb/.bashrc
```

## Configuration de Hive en mode « Remote Metastore »

Référencer dans hive-config.sh le répertoire d'utilisation d'Hadoop

```
sudo nano /usr/local/hive-2.3.0/bin/hive-config.sh
```

Chercher dans le fichier les lignes suivantes :

```
# Allow alternate conf dir location.
HIVE_CONF_DIR="\${HIVE_CONF_DIR:-$HIVE_HOME/conf}"
export HIVE_CONF_DIR=$HIVE_CONF_DIR
export HIVE_AUX_JARS_PATH=$HIVE_AUX_JARS_PATH
```

Ajouter en dessous de ces lignes

```
export HADOOP_HOME=/usr/local/hadoop-2.8.0
```

Créer le fichier hive-site.xml à partir de la version par défaut fourni et l'éditer pour faire la configuration de Hive en mode Remonte Metastore. Ce fichier permet d'indiquer à Hive les paramètres de connexion à la base et le nom des répertoires dans HDFS son utilisation.

```
cp hive-default.xml.template hive-site.xml
sudo gedit /usr/local/hive-2.3.0/conf/hive-site.xml
```

Utilisez la commande `ctrl + f` pour accéder à l'option de rechercher (« find ») sur gedit afin de rechercher le nom (clef <name>) de votre propriété dont vous avez besoin et mettre les valeurs (clef <value>) nécessaires.

```
<property>
  <name>javax.jdo.option.ConnectionURL</name>
  <value>jdbc:mysql://hdmaster:3306/metastore</value>
  <description>
    JDBC connect string for a JDBC metastore.
    To use SSL to encrypt/authenticate the connection
    ↪ , provide database-specific SSL flag in the
    ↪ connection URL.
    For example, jdbc:postgresql://myhost/db?ssl=true
    ↪ for postgres database.
  </description>
</property>

<property>
  <name>javax.jdo.option.ConnectionDriverName</name>
  <value>com.mysql.jdbc.Driver</value>
  <description>Driver class name for a JDBC metastore
  ↪ </description>
</property>

<property>
  <name>javax.jdo.option.ConnectionUserName</name>
  <value>hive</value>
  <description>Username to use against metastore
  ↪ database</description>
```

```
</property>
<property>
  <name>javax.jdo.option.ConnectionPassword</name>
  <value>hive!hive</value>
  <description>password to use against metastore
    ↪ database</description>
</property>

<property>
  <name>hive.metastore.uris</name>
  <value>thrift://192.168.2.120:9083</value>
  <description>Thrift URI for the remote metastore.
    ↪ Used by metastore client to connect to remote
    ↪ metastore.</description>
</property>

<property>
  <name>hive.metastore.warehouse.dir</name>
  <value>/user/hive/warehouse</value>
  <description>location of default database for the
    ↪ warehouse</description>
</property>

<property>
  <name>hive.exec.local.scratchdir</name>
  <value>/tmp/hive</value>
  <description>Local scratch space for Hive jobs</
    ↪ description>
</property>

<property>
  <name>hive.downloaded.resources.dir</name>
  <value>/tmp/hive/\${hive.session.id}_resources</
    ↪ value>
  <description>Temporary local directory for added
    ↪ resources in the remote file system.</
    ↪ description>
</property>
```



```
<property>
  <name>hive.scratch.dir.permission</name>
  <value>777</value>
  <description>The permission for the user specific
    ↪ scratch directories that get created.</
    ↪ description>
</property>
```

### 2.8.1.3 Démarrage des services de Hive

Pour pouvoir se connecter, créer et manipuler des données sur Hive, il est nécessaire de lancer ses services. Le service Metastore lancer et en exécution permet dès et déjà de pouvoir tirer usage du client CLI de Hive. Le service de HiveServer2, d'un autre côté, doit être en exécution si nécessaire de connecter d'autres types d'application à Hive. Car c'est ce service qui fait office de médium d'accès à Beeline et autres langages de programmation. Il faut aussi assurer que les démons Hadoop (HDFS et Yarn) sont bien démarrés.

Démarrer le service Metastore de Hive

```
hive —service metastore
```

A cette étape-là, Le client de base de Hive, CLI permet déjà de faire des manipulations au niveau de la base de données de Hive.

Utilisation du client CLI :

```
hive
```

Dans le client CLI hive, passer les commandes suivantes :

```
hive> show databases ;
hive> use default ;
hive> show tables ;
```

« show databases » pour afficher la liste des base de données, « use default » pour indiquer l'utilisation de la base de données « default », base par défaut de hive, « show tables » pour voir la liste des tables dans la base indiquée.

Démarrer le service HiveServer2 de Hive

```
hiveserver2
```

Les services HiveServer2 est nécessaire pour se connecter à Hive à travers le client Beeline et d'autres programme voulant s'y connecter

Une fois ce service lancé, les autres types clients incluant Beeline peuvent se connecter à la base de données de Hive. Utilisation du client Beeline :

```
beeline
```

Connecter à Hive à travers Beeline

```
beeline> !connect jdbc:hive2://192.168.2.120:10000/ " " "
```

#### 2.8.1.4 Exemple simple d'utilisation de Hive

Dans cet exemple, montre la création d'une base « movielens » et la création d'une table « m\_rating » qui sera remplie à partir d'un fichier. L'exemple utilise les données et fichiers en provenance de « Grouplens ». voir lien permanent de « MovieLens 100K Dataset » pour plus d'information (<http://grouplens.org/datasets/movielens>)

Se connecter à Hive à travers Beeline pour procéder à la creation de la Base de données « movielens ». Utiliser l'instruction qui suite :

```
beeline>CREATE DATABASE movielens;
```

Indiquer l'utilisation de la base movielens avec le mot clef USE :

```
beeline> USE movielens;
```

Utiliser cette instruction pour créer une tables nommée m\_rating dans la base nouvellement créée :

```
CREATE TABLE m_rating (  
  u_id INT,  
  m_id INT,  
  rating INT,  
  timestmp STRING)  
ROW FORMAT DELIMITED  
FIELDS TERMINATED BY '\t'  
STORED AS TEXTFILE;
```

Télécharger le fichier zip de MovieLens en le plaçant dans le répertoire par défaut de l'utilisateur hdb et le désarchiver en étant hors de Beeline.

```

sudo su hdb
cd ~
wget http://files.grouplens.org/datasets/movielens/ml
  ↪ -100k.zip
unzip ml-100k.zip

```

Retourner dans Beeline pour charger le fichier u.data et insérer les lignes dans la table m\_rating en utilisant l'instruction suivante :

```

LOAD DATA LOCAL INPATH '/home/hdb/ml-100k/u.data'
OVERWRITE INTO TABLE m_rating;

```

Vérifier si les lignes ont bien été chargées dans la table avec la requête suivante.

```
beeline> select * from m_rating limit 10;
```

Cette requête permet de calculer la moyenne des Indices « rating » pour chaque film représenté par son identifiant « m\_id »

```

beeline> SELECT m_id, avg(rating) FROM m_rating GROUP
  ↪ BY m_id ;

```

Un aperçu du résultat partiel obtenu :

m_id	_c1
1	3.8783185840707963
2	3.2061068702290076
3	3.0333333333333333
4	3.550239234449761
5	3.302325581395349
6	3.576923076923077
7	3.798469387755102
8	3.9954337899543377
9	3.8963210702341136
10	3.831460674157303
11	3.847457627118644
12	4.385767790262173
13	3.4184782608695654

14	3.9672131147540983	
15	3.7781569965870307	
...		

## 2.9 Spark

Apache Spark est un Framework écrit en Scala pour procéder à de l'analyse de données en utilisant des processus de traitement de données en mémoire dans un environnement distribué.

Spark et Hadoop forment un couple souvent utiliser par les entreprises pour le traitement et l'analyse de données stockées dans HDFS. La raison est d'une part Spark convient le mieux par sa capacité d'effectuer des traitements en temps réel (vitesse de traitement élevée), des analyses avancées et Hadoop en revanche, convient mieux le mieux pour le stockage de données allant de structurées au non-structurées et l'exécution de processus batch (temps différé) pour le traitement sur ces dernières. Cette combinaison en couple permet de tirer avantage de la capacité de stockage d'Hadoop et la vitesse de traitement et d'analyse de Spark.

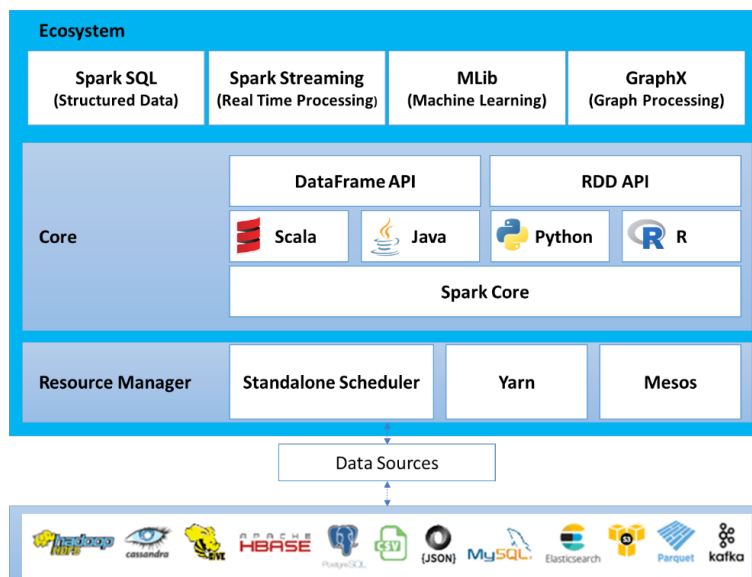


Figure 2.13: Schéma des Composants de Spark

Apache Spark est un regroupement de composants (Figure 2 - 13) qui fonctionne autour du noyau de Spark (Spark Core). Autour du noyau s'intègre des services, des APIs et des bibliothèques de haut niveau.

Spark met à la disposition des programmeurs un ensemble de bibliothèques et de différents langages pour réaliser une application capable d'être exécuté sur un cluster Spark et de produire des codes dans un langage qui convient le mieux au programmeur. Parmi les bibliothèques disponibles actuellement pour l'accomplissement d'application se trouvent MLib pour le Machine Learning, GraphX pour les traitements de données graphes en parallèles et SparkR pour travailler avec le langage R dans l'environnement cluster de Spark. D'autres langages s'ajoutent à la liste comme Java, Scala, Python et SQL.

Spark offre deux (2) APIs, DataFrames et Resilient Distributed Datasets (RDDs). Les DataFrames (API non-typé) et les DataSets (API typé) fournissent une vision de fonctionnement pour l'utilisateur, son mode de fonctionnement réel dans Spark. Pour un utilisateur, ils sont des tables représentées par des lignes et des colonnes distribuées en mémoire sur le cluster. Pour Spark, ceux sont des tables immutables à évolution lente. Spark gère le traitement de données structurées avec SQL ou à travers les Dataframes et les DataSets. Les RDDs en revanche, est l'abstraction de plus bas niveau de Spark représentant une collection d'éléments immuable et partitionnée utilisable en parallèle sur cluster. Pour un utilisateur, chaque ligne représente un objet Java. Ce qui lui donne un contrôle complet et une facilité dans la manipulation des données. Un RDD étant l'abstraction de base, lors de la compilation du code ou se trouve des DataFrames ou des DataSets seront transformés chacun en RDD.

Spark SQL est un module pour travailler avec les données structurées. Spark SQL est utilisé pour l'exécution des requête SQL ou à travers le DataFrame API utilisable dans les langage Java, Python, Scala et R. SQL et DataFrames combinées fournit un moyen commun pour accéder à une variété de sources de données tel que Hive, Avro, Parquet, ORC, JSON, CSV, JDBC et ODBC.

Spark Streaming est un module dans spark pour la réalisation d'application de traitement de données en temps réel. Streaming apporte la capacité de concevoir des applications interactives interactive d'analyse, de surveillance et de détection. Il donne aussi la possibilité de réutiliser le même code de traitement batch, d'effectuer des jointures de données de diffusion (en acquisition temps réel) et des données Historiques ou d'exécuter des requêtes sur des données en mode diffusion (temps réel).




Figure 2.14: Schéma des modes de configuration de Spark

Dans un cluster, Spark nécessite un gestionnaire de ressources (Resource Manager ou Cluster manager) pour l’optimisation, la surveillance (ou le contrôle d’activité) et l’attribution d’exécution de tâches sur le cluster. Il supporte trois (3) types de gestionnaire de ressources dans une configuration en cluster (Figure 2 - 14). Le mode “Standalone ou Native Cluster Manager” où le gestionnaire de ressource est celui de Spark. Le mode « Yarn » utilisant le gestionnaire de ressource d’Hadoop, Yarn. Le mode « Mesos » utilisant le gestionnaire de ressource indépendante Apache Mesos. A noter que Spark est capable en un mode « Local » qui est un mode non-distribué. Dans ce mode, tous ses processus sont dans un seul JVM sur une seule machine, idéal pour les tests et de débogage.

Dans une architecture distribuée d’Apache Spark (Figure 2 - 15), une application Spark s’exécute en un ensemble de processus indépendante sur

---

<sup>30</sup>Source : <https://spark.apache.org/docs/latest/cluster-overview.html>




Figure 2.15: Schéma de l'architecture de fonctionnement de Spark en cluster

le cluster. Une application Spark se compose d'une application principale nommée « Driver Program » et dans Driver program, le SparkContext qui est le coordinateur de ses propres processus s'exécutant sur le cluster. Lors d'un lancement d'une application Spark, SparkContext contacte le gestionnaire de ressources du cluster, qui lui alloue des Executors dans des nœuds esclaves (Worker Node). Un Executor est un processus ayant pour fonction le traitement et le stockage de données pour l'application s'exécutant, à savoir le SparkContext garant de ce processus. Maintenant que le SparkContext est en communication direct avec ses Executors, il peut à présent envoyer le code de l'application aux Executors et qui par la suite envoie les tâches aux Executors pour être traitées. Le code de l'application envoyé est soit un JAR ou un fichier Python qui est transmis à SparkContext.

### 2.9.1 Installation de Apache Spark 2.2.0 un cluster

Cette section montre comment installer Spark en cohabitation avec Hadoop dans un cluster existant (cluster configuré précédemment). Comme on peut voir sur le schéma suivant (Figure 2 - 16), Spark Master sera mis sur le Master Node, le même que celui d'Hadoop Master et deux (2) Spark Slave sur les autres nœuds du cluster (Slave1 et Slave2). Il s'agit d'utiliser Spark avec Yarn, le même gestionnaire de ressources utilisé par Hadoop. Cela

signifie que Spark et Hadoop partageront les mêmes ressources (RAM, CPU, disque). Le Yarn, en tant que gestionnaire de ressources de tous les deux, a la responsabilité de bien équilibrer l'allocation de ressources sur les nœuds esclaves (Slave Node).

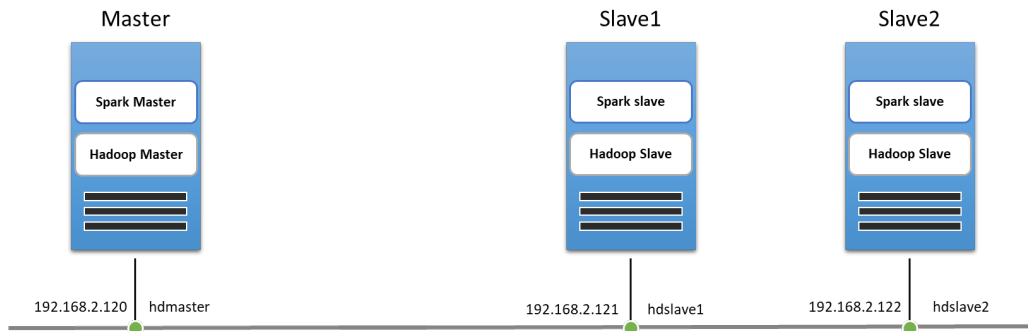


Figure 2.16: Schéma de configuration de Spark sur le cluster d'Hadoop

### 2.9.1.1 Prérequis

Pour cette configuration de Spark en cluster, l'installation du cluster Hadoop doit être déjà mise en place, avec toutes les configurations nécessaires tel que Java 8, création de l'utilisateur hdb, installation de SSH serveur, génération de clef avec ssh-keygen pour l'utilisateur hdb sur toutes les machines du cluster, configuration de fichier `/etc/hosts` (voir section 2.5). Spark est un Framework écrit en scala, il lui faut Scala pour fonctionner. Ce qui fait que Spark a aussi besoin de Java pour son fonctionnement Car Scala est basé sur ce dernier.

### 2.9.1.2 Installation de Scala

La version de Spark 2.2.0 est compiler avec la version 2.11.0 de Scala, Il est recommandé d'utiliser la même version de compilation. Cette version de Scala est trouvable sur le site officiel (<https://www.scala-lang.org/download/2.11.11.html>). Cette étape doit être réalisée sur toutes les machine du cluster.

Aller dans le répertoire `/usr/local/` comme pour l'installation des autres précédemment

```
cd /usr/local
```



Téléchargement de Scala

```
sudo wget https://downloads.lightbend.com/scala
  ↪ /2.11.11/scala-2.11.11.tgz
```

Désarchiver le fichier nouvellement téléchargé (ici scala-2.11.11.tgz)

```
sudo tar -zxf scala-2.11.11.tgz
```

Vérifier si Scala fonctionne Se connecter en tant que hdb

```
sudo su hdb
```

Lancer Scala en tapant la commande suivante :

```
scala
```

Tapez cette instruction pour mettre fin à l'exécution de scala

```
:quit
```

### 2.9.1.3 Installation de Spark

La version binaire d'Apache Spark peut être récupéré sur le site officiel (<https://spark.apache.org/>).

Allez dans un répertoire partager pour que Spark puisse être exécuté par un autre utilisateur. Nous faisons le choix du répertoire `/usr/local/` comme pour l'installation des autres précédemment. Cette étape doit être réalisée que sur le nœud « Master ».

```
cd /usr/local
```

Téléchargement de Spark

```
sudo wget http://mirrors.standaloneinstaller.com/apache
  ↪ /spark/spark-2.2.0/spark-2.2.0-bin-hadoop2.7.tgz
```

Désarchiver le fichier nouvellement téléchargé (ici spark-2.2.0-bin-hadoop2.7.tgz) et renommer le répertoire obtenu en spark-2.2.0.

```
sudo tar xzf spark-2.2.0-bin-hadoop2.7.tgz
sudo mv spark-2.2.0-bin-hadoop2.7 spark-2.2.0
```

Donner l'utilisateur hdb la propriété sur le répertoire

```
sudo chown hdb:hadoop spark-2.2.0
```

Aller dans le répertoire `/conf/` de spark, copier le fichier modèle pour créer le fichier d'environnement Spark (`spark-env.sh`) et Ajouter le fichier les variables qui suit.

```
cd /usr/local/spark-2.2.0/conf/

sudo cp spark-env.sh.template spark-env.sh

sudo nano spark-env.sh
```

```
export JAVA_HOME=/usr/lib/jvm/java-8-oracle

export SPARK_WORKER_CORES=2
```

Toujours dans le répertoire `/conf/`, éditer le fichier « slaves » les alias correspondant aux adresse IP de tous les nœuds esclaves du cluster afin d'indiquer à Spark, les machines agissant comme esclave. Ici, les esclaves sont « `hdslave1` » et « `hdslave2` »

```
sudo nano /usr/local/spark-2.2.0/conf/slaves
```

```
hdslave1
hdslave2
```

### Mise en place des variables d'environnement de Spark

Pour le fonctionnement, une mise en place de variables d'environnement dans le profil de l'utilisateur responsable de l'exécution de Spark doit être effectuées. Cette étape devra être réalisée sur toutes les machine du cluster.

Se connecter en tant que hdb

```
sudo su hdb
```

Ajouter les variables d'environnement de Spark dans le fichier profile de l'utilisateur hdb

```
nano /home/hdb/.bashrc
```

```
# — Spark ENVIRONMENT VARIABLE START — #
export SPARK_HOME=/usr/local/spark-2.2.0
export PATH=$PATH:$SPARK_HOME/bin

export SCALA_HOME=/usr/local/scala-2.11.11
export PATH=$PATH:$SCALA_HOME/bin
# — Spark ENVIRONMENT VARIABLE END — #
```

Rendre la modification du fichier profile active immédiatement

```
source /home/hdb/.bashrc
```

Tester pour voir si Spark-Shell, la ligne de commande de spark fonctionne normalement avec la ligne suivante :

```
spark-shell
```

Tapez cette instruction pour mettre fin à l'exécution de spark-shell

```
:quit
```

## Creation des répertoires d'utilisation de spark dans HDFS

Créer dans HDFS le répertoire /user/spark/ et assigner les droit lecture et écriture pour l'exécution des tâches de spark.

```
hdfs dfs -mkdir /user/spark/
hdfs dfs -chmod g+w /user/spark/
```

### 2.9.1.4 Configuration installation et configuration de Spark sur les nœuds esclaves

Pour la configuration les nœuds esclaves, elle se fera en deux parties. Une partie, sur la machine Master qui consiste à récupérer la configuration initiale du nœud Master et de le copier sur les nœuds esclaves à savoir « hdslave1 » et « hdslave2 ». La seconde sera effectuée sur les nœuds esclaves. Cette seconde partie consiste à déployer le répertoire copié dans son environnement naturel et donner droit à l'utilisateur hdb sur ce dernier.

**Etape 1 à effectuer depuis le nœud Master**

Archiver le répertoire Spark avec tar :

```
sudo tar czf spark-2.2.0.tar.gz spark-2.2.0
```

Copier par SSH le fichier archive de Spark sur tous les nœuds esclaves avec l'utilisateur hdb à partir des commandes qui suit :

```
sudo scp spark-2.2.0.tar.gz hdb@hdslave1:~  
sudo scp spark-2.2.0.tar.gz hdb@hdslave2:~
```

**Etape 2 à effectuer depuis les nœuds esclaves**

Etant sur chaque machine esclave, aller dans le répertoire `/usr/local/` , désarchiver le fichier `spark-2.2.0.tar.gz` qui se trouve dans `/home/hdb/` et copier le répertoire (`spark-2.2.0`) nouvellement crée dans `/usr/local/` en utilisant les commande suivantes :

```
cd /usr/local/  
sudo tar xzf /home/hdb/spark-2.2.0.tar.gz  
sudo cp /home/hdb/spark-2.2.0.tar.gz spark-2.2.0
```

Donner l'utilisateur hdb la propriété sur le répertoire de Spark

```
sudo chown hdb:hadoop spark-2.2.0
```

**2.9.1.5 Démarrage des services des démons de Spark sur le cluster**

Arriver dans cette étape, on peut maintenant démarrer les démons de Spark sur les machines du cluster. De même que Hadoop, Spark peut mettre en route tous les démons Master et Workers à partir du nœud Master.

Lancer cette commande sur le noeud maître en tant que l'utilisateur hdb

```
\$SPARK_HOME/sbin/start-all.sh
```

Verifier sur le nœud maitre avec cette commande, si tous les démons sont en exécution. Le démon du maitre de Spark est « Master »

```
jps
```

```
20226 ResourceManager
19811 NameNode
11509 Jps
20038 SecondaryNameNode
11435 Master
```

Vérifier sur les nœuds esclaves avec cette commande, si tous les démons sont en exécution. Le démon du nœud esclaves de Spark est « Worker »

```
jps
```

```
8561 Jps
8249 NodeManager
7753 DataNode
7964 Worker
```

Pour l'arrêter les démons de Spark, lancer le fichier `$SPARK_HOME/sbin/stop-all.sh` en étant l'utilisateur propriétaire de Spark. Dans notre cas, l'utilisateur est hdb.

### 2.9.1.6 Exemple simple d'exécution d'application sur spark-shell avec Yarn

Dans cette section, on verra à partir d'un exemple de MapReduce de compter de mot en Scala, comment exécuter et traiter des données à partir du Shell de Spark. Dans cet exemple, le Shell de Spark sera connecté en tant que client de du gestionnaire de ressources de Hadoop Yarn. Dans l'exemple, l'usage des fichiers test01 et test02 dans le répertoire `/user/hdb/input_ex` dans HDFS créés précédemment.

Passer cette commande pour lancer le Spark-Shell en tant que client de yarn

```
\$SPARK_HOME/bin/spark-shell --master yarn --deploy-mode client
```

Après avoir exécuter spark-shell en tant que client yarn, exécuter le code compteur de mot dans l'invite Scala de Spark. Le programme MapReduce en paramètre en entrée (input) le répertoire (`/user/hdb/input_ex`) dans HDFS où se trouve les fichiers test01 et test02 et en sortie (output) le répertoire

(/user/hdb/output\_ex\_spark) pour le dépôt des résultats obtenus. A noter que les liens de connexion vers HDFS est hdfs://hdmaster:9000, avec hdmaster, l'alias du nœud maître et le port 9000 pour de connexion au service d'HDFS.

```
val textFile = sc.textFile("hdfs://hdmaster:9000/user/
  ↪ hdb/input_ex")
val text = textFile.flatMap(line => line.split("_"))
val map = text.map(word => (word, 1))
val reduce = map.reduceByKey(_ + _)
reduce.saveAsTextFile("hdfs://hdmaster:9000/user/hdb/
  ↪ output_ex_spark")
```

Les résultats sont dans les fichiers part-00000 à part-xxxx. Selon le volume d'information à stocker, il peut les séparer en plusieurs parties des numérotations continues avec le préfixe « part- ».

Afficher les résultats obtenus :

```
hadoop fs -cat /user/hdb/output_ex_spark/part-*
```

```
(Bye,1)
(Welcome,1)
>Hello,2)
(Yarn,2)
(HDFS,1)
(Hadoop,1)
```

## 2.10 Références du Chapitre 2

[1]T. White, Hadoop: the definitive guide ; [storage and analysis at Internet scale], 4. ed., Updated. Beijing: O'Reilly, 2015.

[2] Apache Hadoop official Documents [En Ligne] Disponible : <https://wiki.apache.org/hadoop>

[1]Manish A. Kukreja, « Apache Hive: Enterprise SQL on Big Data frameworks ». Unpublished, 2016.

[1]A. Thusoo et al., « Hive - a petabyte scale data warehouse using Hadoop », 2010, p. 996-1005.

[1]A. Thusoo et al., « Hive: a warehousing solution over a map-reduce framework », Proceedings of the VLDB Endowment, vol. 2, no 2, p. 1626-1629,

août 2009.

[1]E. Capriolo, D. Wampler, et J. Rutherglen, Programming Hive: [data warehouse and query language for Hadoop], 1. ed. Beijing: O'Reilly, 2012.

[1]S. Ryza, U. Laserson, S. Owen, et J. Wills, Advanced analytics with Spark, First edition. Beijing ; Sebastopol, CA: O'Reilly, 2015.

[1]B. Chambers et M. Zaharia, Spark, the definitive guide: big data processing made simple. 2017.

[1]J. Dean et S. Ghemawat, « MapReduce: simplified data processing on large clusters », Communications of the ACM, vol. 51, no 1, p. 107-113, janv. 2008.